

机器学习基础作业1

宋思逸

2400010816

2026 年 3 月 7 日

1. 证明 $E_{T' \sim \mathcal{D}^{N'}}[\hat{R}_{test}(h_T)] = R(h_T)$

证明.

$$\begin{aligned} E_{T' \sim \mathcal{D}^{N'}}[\hat{R}_{test}(h_T)] &= E_{T' \sim \mathcal{D}^{N'}}\left[\frac{1}{N'} \sum_{i=1}^{N'} L(h_T(x'_i), y'_i)\right] \\ &= \frac{1}{N'} \sum_{i=1}^{N'} E_{T' \sim \mathcal{D}^{N'}}[L(h_T(x'_i), y'_i)] \\ &= \frac{1}{N'} \sum_{i=1}^{N'} E_{x \sim \mathcal{D}}[L(h_T(x), y)] \\ &= E_{x \sim \mathcal{D}}[L(h_T(x), y)] = R(h_T) \end{aligned}$$

□

2. 比较交叉验证法和自助法的异同

交叉验证法：采用无放回的随机采样方式从数据集中抽出一部分作为训练集T，剩下的用作测试集T'，通常采用分层无放回随机采样，并重复若干次这样的划分过程，取均值作为结果。进一步，若将数据集D随即划分为k个互不相交大小相似子集 $D_1, \dots, D_k$ ，并进行k次训练-测试过程，其中第i次将 D_i 为测试集，剩余为训练集。

自助法：从D中有放回抽样随机抽取 $|D|$ 个数据构建数据集T，然后以未被抽中的数据构建测试集T'

相同点：都是将已知数据集中抽出一部分来作为训练集，抽出一部分来作为测试集。

不同点：

- (a) 采样上：前者为无放回采样，不重复不遗漏；后者为有放回采样，天然存在重复数据和未抽到样本
- (b) 前者样本利用率高，偏差小，但会引入方差；后者引入偏差但方差估计更稳定
- (c) 前者训练集和测试集规模差距大，后者弥补了这一问题