

机器学习基础作业5

宋思逸

2400010816

2026 年 4 月 12 日

1. 设训练集

$$D = \{(x_i, y_i)\}_{i=1}^N, \quad x_i \in \mathcal{X}, y \in \mathbb{R} \quad (1)$$

我们希望学习一个模型

$$F_M(x) = \sum_{m=1}^M f_m(x) \quad (2)$$

其中每个 $f_m(x)$ 都是一棵较弱的回归树，希望每一轮能用一棵新树去拟合当前模型的误差或负梯度，逐步提升整体预测能力。

考虑课件中给出的平方误差，我们有如下框架：

输入：训练集 $D = \{(x_i, y_i)\}_{i=1}^N$ ，迭代次数 M ，学习率 η

输出：回归提升树 $F_M(x)$

初始化：

$$F_0(x) = \frac{1}{N} \sum_{i=1}^N y_i \quad (3)$$

for $m=1, 2, \dots, M$ ，计算残差：

$$r_{im} = y_i - F_{m-1}(x_i) \quad (4)$$

用 $\{(x_i, r_{im})\}_{i=1}^N$ 拟合回归树 $f_m(x)$

更新

$$F_m(x) = F_{m-1}(x) + \eta f_m(x) \quad (5)$$

其中 η 为学习率

输出 $F_M(x)$

设损失函数为

$$L(y, F(x)) \quad (6)$$

可以去常数函数为初始模型

$$F_0(x) = \arg \min_c \sum_{i=1}^N L(y_i, c) \quad (7)$$

计算负梯度

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad (8)$$

此即当前模型下损失函数下降最快的方向。

用数据 $\{(x_i, r_{im})\}_{i=1}^N$ 训练回归树，得到叶节点区域 $R_{1m}, \dots, R_{Jm}$

求出最优输出值

$$c_{jm} = \arg \min_c \sum_{x_i \in R_{jm}} L(y_i, F_{m-1}(x_i) + c) \quad (9)$$

将模型更新

$$F_m(x) = F_{m-1}(x) + \eta \sum_{j=1}^J c_{jm} \mathbb{I}(x \in R_{jm}) \quad (10)$$

伪代码如下：

输入：训练集 $D = \{(x_i, y_i)\}_{i=1}^N$ ，迭代次数 M ，叶结点数 J ，学习率 η

输出：提升树模型 $F_M(x)$

初始化：

$$F_0(x) = \arg \min_c \sum_{i=1}^N L(y_i, c) \quad (11)$$

for $m=1, 2, \dots, M$:

计算伪残差

$$r_{im} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{m-1}} \quad (12)$$

用 $\{(x_i, r_{im})\}_{i=1}^N$ 拟合一棵回归树，得到叶区域 $R_{1m}, R_{2m}, \dots, R_{Jm}$

for $j=1, 2, \dots, J$ ，计算

$$c_{jm} = \arg \min_c \sum_{x_i \in R_{jm}} L(y_i, F_{m-1}(x_i) + c) \quad (13)$$

更新模型

$$F_m(x) = F_{m-1}(x) + \eta \sum_{j=1}^J c_{jm} \mathbb{I}(x \in R_{jm}) \quad (14)$$

输出 $F_M(x)$

2.

输入：训练集 D ，树的数量 T ，每次结点划分时随机选取的特征数 k

输出：随机森林模型 $H(x)$

for $t = 1$ to T :

(1)通过bootstrap 从 D 中采样得到 D_t

(2)基于 D_t 训练一棵决策树 h_t :

(i)在每个结点，从全部特征中随机选取 k 个特征

(ii)在这 k 个特征中选最优划分特征

(iii)递归生长，直到满足停止条件

end for

分类： $H(x) = \arg \max_y \sum \mathbb{I}(h_t(x) = y)$

回归： $H(x) = \frac{1}{T} \sum h_t(x)$

算法主要思想：

相同点：

1. 使用bootstrap采样，从原始训练集中构造多个训练子集

2. 各基学习器之间相互独立，可以并行训练
3. 多模型集成可以降低方差，提高泛化能力
4. 都适合不稳定学习器

不同点

对于Bagging

1. 对训练样本进行扰动，训练多个基学习器
2. 主要随机性来自样本扰动
3. 若采用决策树，则每棵树在节点划分时通常仍会在“全部特征”中寻找最有划分。

对于随机森林

1. 引入“特征随机采样”，从而随机性同时来自样本空间扰动和特征空间扰动
2. 节点划分时只在随机选出的部分特征中寻找最优化分，从而减少基学习器相关性

实验验证方面：

与单棵决策树相比，Bagging和随机森林通常都有更好的测试性能，这是因为集成削弱了单棵树过拟合带来的高方差。

在大多数高维数据和特征相关性较强的数据上，随机森林表现优于Bagging，因为其降低了树之间的相似性。若特征数较少且最优特征突出，随机森林无明显优势。少数情况下，额外随机性导致的单树能力下降可能使随机森林与Bagging持平、略差。

从偏差-方差角度来看，单棵决策树偏差低，方差高。Bagging偏差不怎么变，方差明显下降，而随机森林方差进一步下降。

Bagging主要解决模型不稳定问题，而随机森林进一步解决基学习器相关性过高问题。

3. 首先证明连接性：由题意，任取 $x_1, x_2 \in X$ ，那么 x_1 和 x_2 由 x 密度可达，由定义立即推出 x_1 与 x_2 密度相连，从而 X 满足连接性。

接下来考虑最大性：若最大性不成立，那么对于 $x_i \in X$ ， $\exists x_j \notin X$ ，但是 x_j 也是由 x_i 密度可达的。利用定义得到 x_i 由 x_i 密度可达，注意到 x_i 由 x 密度可达，从而根据密度可达的传递性得到 x_j 由 x 密度可达，这就说明了 $x_j \in X$ ，矛盾！从而假设不成立，即最大性成立。