

机器学习基础作业7

宋思逸

2400010816

2026 年 5 月 22 日

1(5)

证明. 对任意固定的 $h \in \mathcal{H}$, 定义

$$p_i = \mathbb{P}_{x \sim D_i}[h(x) \neq f(x)] \quad (1)$$

从而 h 在第 i 个样本上分类正确的概率为

$$\mathbb{P}[h(x_i) = f(x_i)] = 1 - p_i \quad (2)$$

注意到样本互相独立, 从而 h 在整个样本集上不犯错的概率为

$$\mathbb{P}[L_{(S,f)}(h) = 0] = \prod_{i=1}^m (1 - p_i) \quad (3)$$

而在平均分布 $\bar{D}_m$ 下的真实错误率为

$$L_{(\bar{D}_m, f)}(h) = \mathbb{P}_{x \sim \bar{D}_m}[h(x) \neq f(x)] \quad (4)$$

注意到 $\bar{D}_m$ 为 $D_1, D_2, \dots, D_m$ 的平均分布, 从而

$$L_{(\bar{D}_m, f)}(h) = \frac{1}{m} \sum_{i=1}^m \mathbb{P}_{x \sim D_i}[h(x) \neq f(x)] = \frac{1}{m} \sum_{i=1}^m p_i \quad (5)$$

现在假设

$$L_{(\bar{D}_m, f)}(h) > \varepsilon \quad (6)$$

则

$$\frac{1}{m} \sum_{i=1}^m p_i > \varepsilon \quad (7)$$

i.e.

$$\sum_{i=1}^m p_i > \varepsilon m \quad (8)$$

容易得到

$$\prod_{i=1}^m (1 - p_i) \leq \prod_{i=1}^m e^{-p_i} = e^{-\sum_{i=1}^m p_i} < e^{-\varepsilon m} \quad (9)$$

考虑事件

$$\exists h \in \mathcal{H} \quad \text{s.t.} \quad L_{(\bar{D}_m, f)}(h) > \varepsilon \quad \text{and} \quad L_{(S, f)}(h) = 0 \quad (10)$$

从而

$$\mathbb{P}[\exists h \in \mathcal{H} \text{ s.t. } L_{(\bar{D}_m, f)}(h) > \varepsilon \text{ and } L_{(S, f)}(h) = 0] \leq \sum_{h \in \mathcal{H}} \mathbb{P}[L_{(\bar{D}_m, f)}(h) > \varepsilon \text{ and } L_{(S, f)}(h) = 0] \quad (11)$$

从而

$$\mathbb{P}[\exists h \in \mathcal{H} \text{ s.t. } L_{(\bar{D}_m, f)}(h) > \varepsilon \text{ and } L_{(S, f)}(h) = 0] \leq |\mathcal{H}| e^{-\varepsilon m} \quad (12)$$

□

(6)

证明. 设实例空间 $\mathcal{X}$, 标签空间 $\mathcal{Y} = \{0, 1\}$ 。考虑分类器 h 的真实风险

$$L_{\mathcal{D}}(h) = \mathbb{P}_{(x,y) \sim \mathcal{D}}[h(x) \neq y] \quad (13)$$

如果 A 是 $\mathcal{H}$ 的成功不可知PAC学习器, 那么对于任意分布 $\mathcal{D}$, 任意 $\varepsilon, \delta \in (0, 1)$ 只要样本量

$$m \geq m_{\mathcal{H}}^{\text{agn}}(\varepsilon, \delta) \quad (14)$$

算法 A 在样本

$$S = ((x_1, y_1), \dots, (x_m, y_m)) \sim \mathcal{D}^m \quad (15)$$

上输出假设 $A(S)$, 并且至少以 $1 - \delta$ 的概率满足

$$L_{\mathcal{D}}(A(S)) \leq \inf_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \varepsilon \quad (16)$$

现在考虑普通PAC学习中的可实现情形, i.e. $\exists h^* \in \mathcal{H}$ 使得样本标签由 h^* 生成。

$$\mathbb{P}_{(x,y) \sim \mathcal{D}}[y = h^*(x)] = 1 \quad (17)$$

从而

$$L_{\mathcal{D}}(h^*) = \mathbb{P}_{(x,y) \in \mathcal{D}}[h^*(x) \neq y] = 0 \quad (18)$$

于是

$$\inf_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \leq L_{\mathcal{D}}(h^*) = 0 \quad (19)$$

又由于风险本身非负, 从而有

$$\inf_{h \in \mathcal{H}} L_{\mathcal{D}}(h) = 0 \quad (20)$$

代入不可知PAC学习器的保证得到

$$m \geq m_{\mathcal{H}}^{\text{agn}}(\varepsilon, \delta) \quad (21)$$

时, 以至少 $1 - \delta$ 的概率

$$L_{\mathcal{D}}(A(S)) \leq \inf_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \varepsilon = \varepsilon \quad (22)$$

这正是普通PAC学习在可实现情形下的要求: 存在一个样本复杂度函数, 使得当样本量足够大时, 学习器输出的假设真实误差至多为 ε , 失败概率至多为 δ 。

因此令

$$m_{\mathcal{H}}^{\text{PAC}}(\varepsilon, \delta) = m_{\mathcal{H}}^{\text{agn}}(\varepsilon, \delta) \quad (23)$$

得到 $\mathcal{H}$ 是PAC可学习的。

注意到推导未改变算法本身, 我们仍使用同一个算法 A , 从而若 A 为 $\mathcal{H}$ 的成功不可知PAC学习器, 那么在可实现情形下, A 自动满足普通PAC学习器的定义。因此

$$\mathcal{H} \text{ agnostic PAC learnable} \implies \mathcal{H} \text{ PAC learnable} \quad (24)$$

并且如果 A 是 $\mathcal{H}$ 的不可知PAC学习器, 那么同一个 A 也是 $\mathcal{H}$ 的PAC学习器。 $\square$

2.

1. PAC可学习

这里PAC的全称是Probably Approximately Correct。令 m 表示从分布 $\mathcal{D}$ 中独立同分布采样得到的样例数目， $0 < \varepsilon, \delta < 1$ ，对所有分布 $\mathcal{D}$ ，若存在学习算法 $\mathcal{L}$ 和多项式函数 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$ ，使得对于任意 $m \geq \text{poly}(\frac{1}{\varepsilon}, \frac{1}{\delta}, \text{size}(\mathbf{x}), \text{size}(c))$ ， $\mathcal{L}$ 都能从假设空间 $\mathcal{H}$ 中PAC辨识概念类 $\mathcal{C}$ ，则称概念类 $\mathcal{C}$ 对假设空间 $\mathcal{H}$ 而言是PAC可学习的。这里PAC辨识是指：对 $0 < \varepsilon, \delta < 1$ ，所有 $c \in \mathcal{C}$ 和分布 $\mathcal{D}$ ，存在学习算法 $\mathcal{L}$ ，其输出假设 $h \in \mathcal{H}$ 满足

$$\mathbb{P}(L(h) \leq \varepsilon) \geq 1 - \delta \quad (25)$$

2. 不可知PAC可学习性 令 m 表示从分布 $\mathcal{D}$ 中独立同分布采样得到的样例数目， $0 < \varepsilon, \delta < 1$ ，对所有分布 $\mathcal{D}$ ，若存在学习算法 $\mathcal{L}$ 和多项式函数 $\text{poly}(\cdot, \cdot, \cdot, \cdot)$ ，使得对于任何 $m \geq \text{poly}(\frac{1}{\varepsilon}, \frac{1}{\delta}, \text{size}(\mathbf{x}), \text{size}(c))$ ， $\mathcal{L}$ 能从假设空间 $\mathcal{H}$ 中输出满足如下条件的假设 h ：

$$\mathbb{P}(L(h) - \min_{h' \in \mathcal{H}} L(h') \leq \varepsilon) \geq 1 - \delta \quad (26)$$

3. 一致收敛性质 设假设类为 $\mathcal{H}$ ，真实误差为

$$L_{\mathcal{D}}(h) = \mathbb{P}_{(x,y) \sim \mathcal{D}}[h(x) \neq y] \quad (27)$$

经验误差为

$$L_S(h) = \frac{1}{m} \sum_{i=1}^m \mathbb{I}[h(x_i) \neq y_i] \quad (28)$$

如果对于任意分布 $\mathcal{D}$ ， $\varepsilon > 0, \delta > 0$ ，当样本量 m 足够大时，以至少 $1 - \delta$ 的概率，对所有 $h \in \mathcal{H}$ ，同时有

$$|L_{\mathcal{D}}(h) - L_S(h)| \leq \varepsilon \quad (29)$$

则称假设类 $\mathcal{H}$ 具有一致收敛性质。这里的一致指的是误差收敛不只是对某一个固定假设 h 成立，而是对所有 $h \in \mathcal{H}$ 都成立。

4. 估计误差 设学习算法在样本 S 上输出经验风险最小化假设

$$\hat{h} = \operatorname{argmin}_{h \in \mathcal{H}} L_S(h) \quad (30)$$

而真实风险最小的假设为

$$h^* = \operatorname{argmin}_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \quad (31)$$

则估计误差定义为

$$L_{\mathcal{D}}(\hat{h}) - L_{\mathcal{D}}(h^*) \quad (32)$$

它表示由于只能使用有限训练样本，算法选出的 $\hat{h}$ 比真实的 h^* 相比多多少。

3.可令

$$h^* \in \arg \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \quad (33)$$

定义

$$Z(S) = L_{\mathcal{D}}(A(S)) - \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \quad (34)$$

因为 $A(S) \in \mathcal{H}$ ，从而

$$L_{\mathcal{D}}(A(S)) \geq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \quad (35)$$

于是

$$Z(S) \geq 0 \quad (36)$$

考虑算法A满足的条件，取 $m \geq m_{\varepsilon\delta}$ 得到

$$\mathbb{E}_{S \sim \mathcal{D}^m} [L_{\mathcal{D}}(A(S))] \leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \varepsilon\delta \quad (37)$$

于是

$$\mathbb{E}[Z(S)] = \mathbb{E}[L_{\mathcal{D}}(A(S)) - \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h)] \leq \varepsilon\delta \quad (38)$$

注意到 $Z(S) \geq 0$ ，由Markov不等式可以得到

$$\mathbb{P}[Z(S) > \varepsilon] \leq \frac{\mathbb{E}[Z(S)]}{\varepsilon} \leq \frac{\varepsilon\delta}{\varepsilon} = \delta \quad (39)$$

i.e.

$$\mathbb{P}[L_{\mathcal{D}}(A(S)) - \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) > \varepsilon] \leq \delta \quad (40)$$

于是以至少 $1 - \delta$ 的概率有

$$L_{\mathcal{D}}(A(S)) - \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) \leq \varepsilon \quad (41)$$

i.e.

$$L_{\mathcal{D}}(A(S)) \leq \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h) + \varepsilon \quad (42)$$