

计算方法 B 参考答案-数值最优化方法

刘宇扬

2025 Fall

1 作业九

习题二: 3、5、7、8、10

1.1 第 3 题

标准的 Rosenbrock 函数定义为:

$$f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2 \quad (1)$$

1. 验证 $x^* = (1, 1)^T$ 是极小点

计算梯度 $\nabla f(x)$:

$$\frac{\partial f}{\partial x_1} = 200(x_2 - x_1^2)(-2x_1) - 2(1 - x_1) = -400x_1(x_2 - x_1^2) - 2(1 - x_1)$$

$$\frac{\partial f}{\partial x_2} = 200(x_2 - x_1^2)$$

令 $\nabla f(x) = 0$: 由 $\frac{\partial f}{\partial x_2} = 0 \implies x_2 - x_1^2 = 0 \implies x_2 = x_1^2$ 。代入第一式: $-400x_1(0) - 2(1 - x_1) = 0 \implies 1 - x_1 = 0 \implies x_1 = 1$ 。故 $x_2 = 1^2 = 1$ 。唯一驻点为 $x^* = (1, 1)^T$ 。

计算 Hesse 矩阵 (即 $G(x)$):

$$G(x) = \nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix}$$

$$\frac{\partial^2 f}{\partial x_1^2} = -400(x_2 - x_1^2) - 400x_1(-2x_1) + 2 = -400x_2 + 1200x_1^2 + 2$$

$$\frac{\partial^2 f}{\partial x_1 \partial x_2} = -400x_1, \quad \frac{\partial^2 f}{\partial x_2^2} = 200$$

即:

$$G(x) = \begin{bmatrix} 1200x_1^2 - 400x_2 + 2 & -400x_1 \\ -400x_1 & 200 \end{bmatrix} \quad (2)$$

在 $x^* = (1, 1)^T$ 处:

$$G(1, 1) = \begin{bmatrix} 1200 - 400 + 2 & -400 \\ -400 & 200 \end{bmatrix} = \begin{bmatrix} 802 & -400 \\ -400 & 200 \end{bmatrix}$$

由于 $\det(G) = 802 \times 200 - (-400)^2 = 160400 - 160000 = 400 > 0$, 且对角元之和 $802 + 200 > 0$, 故两个特征值均正, $G(1, 1)$ 正定。因此 x^* 是严格局部极小点 (也是全局极小点, 因为显然 $f(x) \geq 0$ 且 $f(1, 1) = 0$)。

2. 证明 $G(x)$ 奇异的条件

$G(x)$ 奇异当且仅当 $\det(G(x)) = 0$ 。

$$\begin{aligned}\det(G(x)) &= 200(1200x_1^2 - 400x_2 + 2) - (-400x_1)^2 \\ &= 240000x_1^2 - 80000x_2 + 400 - 160000x_1^2 \\ &= 80000x_1^2 - 80000x_2 + 400\end{aligned}$$

令 $\det(G(x)) = 0$:

$$80000(x_1^2 - x_2) + 400 = 0 \implies x_2 - x_1^2 = \frac{400}{80000} = \frac{1}{200} = 0.005$$

证毕。

3. 证明区域正定性

$G(x)$ 正定等价于两个特征值均正, 即 $\det(G(x)) > 0$ 且 $\text{Tr}(G(x)) > 0$: 1. $\text{Tr}(G(x)) = 1200x_1^2 - 400x_2 + 202 > 0$ 。

由于 $\text{Tr}(G(x)) = 800x_1^2 + 202 - 400(x_2 - x_1^2)$, 所以若要 $\text{Tr}(G(x)) > 0$, 则只要满足:

$$x_2 - x_1^2 < 0.5 \quad (3)$$

2. $\det(G(x)) > 0$ 。

由上一问可知, $\det(G(x)) = 80000(x_1^2 - x_2) + 400 = 80000[0.005 - (x_2 - x_1^2)]$ 。若要 $\det(G(x)) > 0$, 则需满足:

$$x_2 - x_1^2 < 0.005 \quad (4)$$

现考察区域 $f(x) < 0.0025$ 。

$$f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2 < 0.0025$$

由于 $(1 - x_1)^2 \geq 0$, 必有:

$$100(x_2 - x_1^2)^2 \leq f(x) < 0.0025$$

$$(x_2 - x_1^2)^2 < 0.000025$$

开平方得:

$$|x_2 - x_1^2| < \sqrt{0.000025} = 0.005$$

即:

$$-0.005 < x_2 - x_1^2 < 0.005$$

上式右端 $x_2 - x_1^2 < 0.005$ 满足了条件 (4) 与 (3)。因此对于所有满足 $f(x) < 0.0025$ 的 x , 都有 $\det(G(x)) > 0$ 和 $\text{Tr}(G(x)) > 0$, 从而 $G(x)$ 是正定的。

1.2 第 5 题

精确线搜索的目标是求解一元优化问题:

$$\min_{\alpha \geq 0} \varphi(\alpha) := f(x_k + \alpha d_k)$$

将 $f(x)$ 展开:

$$\begin{aligned}\varphi(\alpha) &= \frac{1}{2}(x_k + \alpha d_k)^T G(x_k + \alpha d_k) + b^T(x_k + \alpha d_k) \\ &= \frac{1}{2}x_k^T G x_k + \alpha d_k^T G x_k + \frac{1}{2}\alpha^2 d_k^T G d_k + b^T x_k + \alpha b^T d_k\end{aligned}$$

这里利用了 $x_k^T G d_k = d_k^T G x_k$ (G 对称)。

由于上式是关于 α 的二次函数, 其最值在 α 求导为 0 的点取到:

$$\varphi'(\alpha) = d_k^T G x_k + \alpha d_k^T G d_k + b^T d_k = 0$$

整理得:

$$(G x_k + b)^T d_k + \alpha d_k^T G d_k = 0$$

引入梯度 $g_k := \nabla f(x_k) = G x_k + b$, 代入上式得:

$$g_k^T d_k + \alpha d_k^T G d_k = 0$$

求解 α 的最值:

$$\alpha_* = -\frac{g_k^T d_k}{d_k^T G d_k}$$

由于 G 正定且 d_k 为下降方向 (即 $d_k \neq 0$ 且 $g_k^T d_k < 0$), 该分母非零且 $\alpha_* > 0$ 。

于是所求的精确线搜索步长为:

$$\alpha_k = \alpha_* = -\frac{g_k^T d_k}{d_k^T G d_k}$$

1.3 第 7 题

(a) $f(x) = 2x_1^2 + x_2^2 - 2x_1x_2 + 2x_1^3 + x_1^4$

1. 求梯度

$$g(x) = \nabla f(x) = \begin{bmatrix} 4x_1 - 2x_2 + 6x_1^2 + 4x_1^3 \\ 2x_2 - 2x_1 \end{bmatrix}$$

2. 解驻点方程 $g(x) = 0$

由第 2 分量: $2x_2 - 2x_1 = 0 \implies x_2 = x_1$ 。代入第 1 分量:

$$4x_1 - 2x_1 + 6x_1^2 + 4x_1^3 = 0$$

$$2x_1 + 6x_1^2 + 4x_1^3 = 0 \implies 2x_1(1 + 3x_1 + 2x_1^2) = 0$$

因式分解 $2x_1^2 + 3x_1 + 1 = (2x_1 + 1)(x_1 + 1)$ 。故方程的根为 $x_1 = 0$, $x_1 = -1/2$, $x_1 = -1$ 。
对应的驻点为:

$$P_1 = (0, 0), \quad P_2 = (-0.5, -0.5), \quad P_3 = (-1, -1)$$

3. 计算 Hesse 矩阵

$$G(x) = \begin{bmatrix} 4 + 12x_1 + 12x_1^2 & -2 \\ -2 & 2 \end{bmatrix}$$

4. 分类

- 对于 $P_1(0,0)$: $G = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix}$ 。 $\det(G) = 8 - 4 = 4 > 0$, $\text{Tr}(G) > 0$ 。所以正定, 为**严格极小点**。
- 对于 $P_2(-0.5, -0.5)$: $G = \begin{bmatrix} 1 & -2 \\ -2 & 2 \end{bmatrix}$ 。 $\det(G) = 2 - 4 = -2 < 0$ 。所以 G 的特征值一正一负, 为**鞍点**。
- 对于 $P_3(-1, -1)$: $G = \begin{bmatrix} 4 & -2 \\ -2 & 2 \end{bmatrix}$ 。 $\det(G) = 4 > 0$, $\text{Tr}(G) > 0$ 。所以正定, 为**严格极小点**。

(b) $f(x) = 2x_1^3 - 3x_1^2 - 6x_1x_2(x_1 - x_2 - 1) = 2x_1^3 - 3x_1^2 - 6x_1^2x_2 + 6x_1x_2^2 + 6x_1x_2$

1. 求梯度

$$g_1 = \frac{\partial f}{\partial x_1} = 6x_1^2 - 6x_1 - 12x_1x_2 + 6x_2^2 + 6x_2$$

$$g_2 = \frac{\partial f}{\partial x_2} = -6x_1^2 + 12x_1x_2 + 6x_1$$

2. 解驻点方程

观察到

$$g_1 + g_2 = 6x_2^2 + 6x_2 + 6x_1 - 6x_1 = 6x_2^2 + 6x_2$$

所以当 $g_1 = 0, g_2 = 0$, 必有 $6x_2(x_2 + 1) = 0$, 故 $x_2 = 0$ 或 $x_2 = -1$ 。

- Case 1: $x_2 = 0$ 。代入 $g_2 = 0 \implies -6x_1^2 + 6x_1 = 0 \implies -6x_1(x_1 - 1) = 0$ 。得 $x_1 = 0$ 或 $x_1 = 1$ 。代回 $g_1 = 0$ 也成立, 所以驻点: $P_1(0,0), P_2(1,0)$ 。
- Case 2: $x_2 = -1$ 。代入 $g_2 = 0 \implies -6x_1^2 - 12x_1 + 6x_1 = -6x_1^2 - 6x_1 = 0 \implies -6x_1(x_1 + 1) = 0$ 。得 $x_1 = 0$ 或 $x_1 = -1$ 。代回 $g_1 = 0$ 也成立, 所以驻点: $P_3(0,-1), P_4(-1,-1)$ 。

3. 计算 Hesse 矩阵与分类

$$G(x) = \begin{bmatrix} 12x_1 - 6 - 12x_2 & -12x_1 + 12x_2 + 6 \\ -12x_1 + 12x_2 + 6 & 12x_1 \end{bmatrix}$$

4. 分类

- 对于 $P_1(0,0)$: $G = \begin{bmatrix} -6 & 6 \\ 6 & 0 \end{bmatrix}$, $\det(G) = -36 < 0$ 。所以 G 的特征值一正一负, 为**鞍点**。
- 对于 $P_2(1,0)$: $G = \begin{bmatrix} 6 & -6 \\ -6 & 12 \end{bmatrix}$ 。 $\det(G) = 72 - 36 = 36 > 0$, $\text{Tr}(G) > 0$ 。所以正定, 为**严格极小点**。
- 对于 $P_3(0,-1)$: $G = \begin{bmatrix} 6 & -6 \\ -6 & 0 \end{bmatrix}$, $\det(G) = -36 < 0$ 。所以 G 的特征值一正一负, 为**鞍点**。
- 对于 $P_4(-1,-1)$: $G = \begin{bmatrix} -6 & 6 \\ 6 & -12 \end{bmatrix}$ 。 $\det(G) = 72 - 36 = 36 > 0$, $\text{Tr}(G) < 0$ 。所以负定, 为**严格极大点**。

1.4 第 8 题

初始化: 区间 $[a, b] = [0, 1]$, 精度 $\varepsilon = 0.01$ 。黄金分割比 $\tau = \frac{\sqrt{5}-1}{2} \approx 0.618$ 。

迭代过程:

第 1 步: $a_0 = 0, b_0 = 1, L_0 = b_0 - a_0 = 1 > \varepsilon$ 。

所以计算左测试点

$$a_0^l = a_0 + (1 - \tau)L_0 = 0.382$$

与右测试点

$$a_0^r = a_0 + \tau L_0 = 0.618$$

函数值: $\varphi(a_0^l) = 1 - 0.382e^{-0.382^2} \approx 1 - 0.382(0.864) = 0.670$ 。 $\varphi(a_0^r) = 1 - 0.618e^{-0.618^2} \approx 1 - 0.618(0.682) = 0.579$ 。比较: $\varphi(a_0^r) < \varphi(a_0^l)$, 极小点在右侧, 新区间 $[a_1, b_1] = [a_0^l, b_0] = [0.382, 1]$ 。

第 2 步: $a_1 = 0.382, b_1 = 1, L_0 = b_0 - a_0 = 0.618 > \varepsilon$ 。

所以继承左测试点

$$a_1^l = a_0^r = 0.618$$

计算右测试点

$$a_1^r = a_1 + \tau L_1 = 0.764$$

函数值: $\varphi(a_1^r) = 0.574$ 。

比较: $\varphi(a_1^r) < \varphi(a_1^l) = 0.579$, 极小点在右侧, 新区间 $[a_2, b_2] = [a_1^l, b_1] = [0.618, 1]$ 。

.....

经过第 9 次迭代后, 新区间为 $[0.703, 0.712]$ 。区间长度 $L_{10} = 0.712 - 0.703 = 0.009$ 。满足 $L_{10} < \varepsilon = 0.01$ 。

最终结果:

近似极小点可取区间中点:

$$\alpha^* \approx \frac{0.703 + 0.712}{2} = 0.7075$$

对应的极小值为 $\varphi(0.7075) \approx 0.571$ 。

真实极小点分析与验证

为了验证上述数值方法的正确性, 我们对原函数进行解析求解。

目标函数:

$$\varphi(\alpha) = 1 - \alpha e^{-\alpha^2}$$

对 α 求一阶导数:

$$\varphi'(\alpha) = 0 - \left(1 \cdot e^{-\alpha^2} + \alpha \cdot e^{-\alpha^2} \cdot (-2\alpha)\right) = -e^{-\alpha^2}(1 - 2\alpha^2)$$

令 $\varphi'(\alpha) = 0$ 求驻点:

$$-e^{-\alpha^2}(1 - 2\alpha^2) = 0$$

由于 $e^{-\alpha^2} > 0$ 恒成立, 故有:

$$1 - 2\alpha^2 = 0 \implies \alpha^2 = \frac{1}{2} \implies \alpha = \pm \frac{\sqrt{2}}{2}$$

考虑到初始区间为 $[0, 1]$ ，取正根：

$$\alpha_{true} = \frac{\sqrt{2}}{2} \approx 0.70710678...$$

该点的函数值为：

$$\varphi(\alpha_{true}) = 1 - \frac{1}{\sqrt{2}}e^{-0.5} = 1 - \frac{1}{\sqrt{2}}\frac{1}{\sqrt{e}} = 1 - \frac{1}{\sqrt{2e}} \approx 1 - 0.42888 \approx 0.57112$$

误差分析：

数值解结果 $\alpha^* \approx 0.7075$ 与真实解 $\alpha_{true} \approx 0.7071$ 非常接近。

绝对误差 $|0.7075 - 0.7071| = 0.0004$ ，远小于预设精度 $\varepsilon = 0.01$ 。

计算结果所在的最终区间 $[0.703, 0.712]$ 包含了真实的极小点 0.7071 ，证明了 0.618 算法在该问题上的有效性。

1.5 第 10 题

记 $\varphi_1 = \varphi(\alpha_1), \varphi'_1 = \varphi'(\alpha_1), \varphi_2 = \varphi(\alpha_2), \varphi'_2 = \varphi'(\alpha_2)$ 。

构造 Hermite 插值多项式形式：

$$p(\alpha) = c_0 + c_1(\alpha - \alpha_1) + c_2(\alpha - \alpha_1)^2 + c_3(\alpha - \alpha_1)^3$$

由插值条件可定系数：1. $p(\alpha_1) = \varphi_1 \implies c_0 = \varphi_1$ 。2. $p'(\alpha_1) = \varphi'_1 \implies c_1 = \varphi'_1$ 。3. 令 $\Delta\alpha = \alpha_2 - \alpha_1$ 。在 α_2 处满足条件：

$$\begin{cases} \varphi_1 + \varphi'_1\Delta\alpha + c_2(\Delta\alpha)^2 + c_3(\Delta\alpha)^3 = \varphi_2 \\ \varphi'_1 + 2c_2\Delta\alpha + 3c_3(\Delta\alpha)^2 = \varphi'_2 \end{cases}$$

解此方程组（令 $A = c_2(\Delta\alpha)^2, B = c_3(\Delta\alpha)^3$ ）：

$$\begin{cases} A + B = \varphi_2 - \varphi_1 - \varphi'_1\Delta\alpha \\ 2A + 3B = (\varphi'_2 - \varphi'_1)\Delta\alpha \end{cases}$$

解得：

$$\begin{cases} A = 3(\varphi_2 - \varphi_1 - \varphi'_1\Delta\alpha) - (\varphi'_2 - \varphi'_1)\Delta\alpha \\ B = (\varphi'_2 - \varphi'_1)\Delta\alpha - 2(\varphi_2 - \varphi_1 - \varphi'_1\Delta\alpha) \end{cases}$$

从而得到 c_2, c_3 ：

$$c_2 = \frac{3(\varphi_2 - \varphi_1) - (\varphi'_2 - \varphi'_1)\Delta\alpha}{\Delta\alpha^2}, \quad c_3 = \frac{(\varphi'_2 - \varphi'_1)\Delta\alpha - 2(\varphi_2 - \varphi_1 - \varphi'_1\Delta\alpha)}{\Delta\alpha^3}$$

求 $p(\alpha)$ 的极小点，即令 $p'(\alpha) = c_1 + 2c_2(\alpha - \alpha_1) + 3c_3(\alpha - \alpha_1)^2 = 0$ 。这是一个关于 $(\alpha - \alpha_1)$ 的二次方程。根据二次方程求根公式，并取使得二阶导 > 0 （极小值）的根，可得：

$$\alpha^* = \alpha_1 + \frac{-c_2 + \sqrt{c_2^2 - 3c_1c_3}}{3c_3} \quad (5)$$

令 $s = \alpha_2 - \alpha_1, z = \varphi'_1 + \varphi'_2 - 3\frac{\varphi_2 - \varphi_1}{s}, w = \sqrt{z^2 - \varphi'_1\varphi'_2}$ 。则极小点为：

$$\alpha^* = \alpha_2 - \frac{\varphi'_2 + w - z}{\varphi'_2 - \varphi'_1 + 2w}(\alpha_2 - \alpha_1) \quad (6)$$

2 作业十

习题三：3、5、7、15

2.1 第 3 题

首先将目标函数写成标准二次型形式 $f(x) = \frac{1}{2}x^T Qx + b^T x$ 。

$$f(x) = \frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 4 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

故 Hasse 矩阵 $Q = \text{diag}(2, 4)$ ，向量 $b = [4, 4]^T$ 。全局极小点 x^* 满足 $Qx^* + b = 0$ ，解得：

$$x^* = \begin{bmatrix} -2 \\ -1 \end{bmatrix}$$

最速下降法的迭代格式为 $x^{(k+1)} = x^{(k)} - \alpha_k g_k$ ，其中 $g_k = \nabla f(x^{(k)}) = Qx^{(k)} + b = Q(x^{(k)} - x^*)$ 。由上一次作业第 5 题结论，精确线搜索步长为 $\alpha_k = \frac{g_k^T g_k}{g_k^T Q g_k}$ 。

令误差向量 $e_k = x^{(k)} - x^*$ 。则迭代关系可转化为误差的递推：

$$e_{k+1} = e_k - \alpha_k Q e_k = (I - \alpha_k Q) e_k$$

我们需要证明的通项公式等价于证明：

$$e_{k+1} = \begin{bmatrix} \frac{2}{3^k} - 2 - (-2) \\ (-\frac{1}{3})^k - 1 - (-1) \end{bmatrix} = \begin{bmatrix} \frac{2}{3^k} \\ (-\frac{1}{3})^k \end{bmatrix}$$

我们使用数学归纳法进行证明。

当 $k=0$ 时： $x^{(1)} = (0, 0)^T$ ，此时误差 $e_1 = (2, 1)^T$ 。成立。

若 k 成立，则此时

$$g_k = Q(x^{(k)} - x^*) = Q e_k = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} \frac{2}{3^k} \\ (-\frac{1}{3})^k \end{bmatrix} = \begin{bmatrix} \frac{4}{3^k} \\ 4(-\frac{1}{3})^k \end{bmatrix}$$

代入有

$$\alpha_k = \frac{g_k^T g_k}{g_k^T Q g_k} = \frac{\frac{16}{3^{2k}} + \frac{16}{3^{2k}}}{\frac{32}{3^{2k}} + \frac{64}{3^{2k}}} = \frac{1}{3}$$

于是

$$e_{k+1} = (I - \alpha_k Q) e_k = \begin{bmatrix} 1 - 2/3 & 0 \\ 0 & 1 - 4/3 \end{bmatrix} \begin{bmatrix} \frac{2}{3^k} \\ (-\frac{1}{3})^k \end{bmatrix} = \begin{bmatrix} \frac{2}{3^{k+1}} \\ (-\frac{1}{3})^{k+1} \end{bmatrix}$$

即归纳假设对 $k+1$ 也成立。

证毕。

2.2 第 5 题

首先对 f 求导：

$$g(x) := f'(x) = \frac{11}{91}x^5 - \frac{38}{91}x^3 + x$$
$$G(x) := f''(x) = \frac{55}{91}x^4 - \frac{114}{91}x^2 + 1$$

令 $t = x^2 \geq 0$, 考察 $h(t) = \frac{55}{91}t^2 - \frac{114}{91}t + 1$. 判别式 $\Delta = (\frac{114}{91})^2 - 4(\frac{55}{91}) = \frac{114^2 - 4 \cdot 91 \cdot 55}{91^2} = -\frac{7024}{91^2} < 0$. 由于开口向上, 故 $h(t) > 0$ 恒成立。这意味着二阶导 $G(x) > 0$ 对所有实数 x 成立, 即目标函数是严格凸的, 每步产生的 G_k **均为正定** (在此处即为正数)。

因为 $G_k > 0$, Newton 方向为 $d_k = -g_k/G_k$ 必定是下降方向。

对于基本 Newton 法 $x_{k+1} = x_k - \frac{g(x_k)}{G(x_k)} =: N(x_k)$ 。

我们首先发现 f 是偶函数, 一阶导 $g(x)$ 为奇函数, 二阶导 $G(x)$ 为偶函数。所以 $N(x)$ 为奇函数。

计算可知

$$\begin{aligned} N(x) &= x - \frac{g(x)}{G(x)} \\ &= x - \frac{x(\frac{11}{91}x^4 - \frac{38}{91}x^2 + 1)}{\frac{55}{91}x^4 - \frac{114}{91}x^2 + 1} \\ &= x(1 - \frac{\frac{11}{91}(x^2 - 1)^2 - \frac{16}{91}(x^2 - 1) + \frac{64}{91}}{\frac{55}{91}(x^2 - 1)^2 - \frac{4}{91}(x^2 - 1) + \frac{32}{91}}) \\ &= x(1 - \frac{11(x^2 - 1)^2 - 16(x^2 - 1) + 64}{55(x^2 - 1)^2 - 4(x^2 - 1) + 32}) \\ &= x \frac{44(x^2 - 1)^2 + 12(x^2 - 1) - 32}{55(x^2 - 1)^2 - 4(x^2 - 1) + 32} \end{aligned}$$

所以

$$\begin{aligned} N(x)^2 - 1 &= x^2(1 - \frac{22(x^2 - 1)^2 - 32(x^2 - 1) + 128}{55(x^2 - 1)^2 - 4(x^2 - 1) + 32} + (\frac{11(x^2 - 1)^2 - 16(x^2 - 1) + 64}{55(x^2 - 1)^2 - 4(x^2 - 1) + 32})^2) - 1 \\ &= (x^2 - 1) - x^2(\frac{22(x^2 - 1)^2 - 32(x^2 - 1) + 128}{55(x^2 - 1)^2 - 4(x^2 - 1) + 32} - (\frac{11(x^2 - 1)^2 - 16(x^2 - 1) + 64}{55(x^2 - 1)^2 - 4(x^2 - 1) + 32})^2) \end{aligned}$$

下面考虑 $R(t) := \frac{22t^2 - 32t + 128}{55t^2 - 4t + 32} - (\frac{11t^2 - 16t + 64}{55t^2 - 4t + 32})^2$, 则通分并配方得到:

$$\begin{aligned} R(t) &= \frac{(22t^2 - 32t + 128)(55t^2 - 4t + 32) - (11t^2 - 16t + 64)^2}{(55t^2 - 4t + 32)^2} \\ &= \frac{(11t^2 - 16t + 64)(99t^2 + 8t)}{(55t^2 - 4t + 32)^2} \\ &= \frac{((t - 8)^2 + 10t^2)t(99t + 8)}{((t - 2)^2 + 54t^2 + 28)^2} \end{aligned}$$

上式在 $t > 0$ 时为正数, 而 $t = 0$ 时为 0。

所以我们可知当 $x_k^2 - 1 > 0$ 时, 有

$$x_{k+1}^2 - 1 = N(x_k)^2 - 1 = (x_k^2 - 1) - x_k^2 R(x_k^2 - 1) < x_k^2 - 1$$

下面来证明 $x_k^2 - 1 > 0$ 恒成立。

由于上面证明的单调性, 所以 $x_k^2 - 1 \leq x_0^2 - 1 = 0.0201$ 。在 $x_k^2 - 1 > 0$ 时, 有

$$\begin{aligned} x_{k+1}^2 - 1 &= (x_k^2 - 1) - x_k^2 R(x_k^2 - 1) \\ &= (x_k^2 - 1)(1 - x_k^2 \frac{((t_k - 8)^2 + 10t_k^2)(99t_k + 8)}{((t_k - 2)^2 + 54t_k^2 + 28)^2}) \\ &\geq (x_k^2 - 1)(1 - 1.0201 * \frac{(8^2 + 10 * 0.0201^2) * (99 * 0.0201 + 8)}{28^2}) \\ &= (x_k^2 - 1)(1 - 0.832) \\ &> 0 \end{aligned}$$

其中 $t_k := x_k^2 - 1 \in (0, 0.0201]$ 。所以归纳可知 $x_k^2 - 1 > 0$ 恒成立。

于是 $x_k^2 - 1$ 单减有下界，于是一定收敛。此时由于 $x_k^2 > 1$ ，所以一定有 $R(x_k^2 - 1) \rightarrow 0$ ，而由于配方式子可知只有 t 这一项没有正下界，所以 $x_k^2 - 1 \rightarrow 0$ ，即 $x_k^2 \rightarrow 1$ （实际上更严格来说是从正方向趋于 1）。

此时可知 $0 < x_k^2 - 1 < x_0^2 - 1 < 0.5$ 。所以

$$\begin{aligned} x_{k+1} &= N(x_k) \\ &= x_k \frac{44(x_k^2 - 1)^2 + 12(x_k^2 - 1) - 32}{55(x_k^2 - 1)^2 - 4(x_k^2 - 1) + 32} \end{aligned}$$

而分母恒正，由二次函数性质 $44t^2 + 12t - 32$ 在 $t \in (0, 0.5)$ 上恒为负，所以分子恒负。于是 x_{k+1} 与 x_k 不同号。

所以结合 $x_k^2 \rightarrow 1$ 与 x_{k+1} 与 x_k 不同号，可知 $\{x_k\}$ 的聚点有且仅有 ± 1 。

此外由于 x_k^2 单调递减，所以 $|x_k|$ 单调递减。而 $f(x)$ 为偶函数且为凸函数，在 0 处取唯一极小值，所以 f 在 $(-\infty, 0)$ 上单调递减，在 $(0, +\infty)$ 上单调递增。所以 f 关于 $|x|$ 单调递增。于是可知 $\{f_k = f(x_k)\}$ 单调下降。

又由于 g 为连续函数，所以 $g(x_{2m}) \rightarrow g(1) = \frac{64}{91}$ ，而 $g(x_{2m+1}) \rightarrow g(-1) = -\frac{64}{91}$ 。于是 $\lim_{k \rightarrow \infty} g_k$ 根本不存在，也不会趋于 0。

最后我们验证对于任意 $\rho > 0$ ，当 k 充分大时，对于基本 Newton 法， $\alpha_k d_k = -\frac{g(x_k)}{G(x_k)}$ ，所以：

$$f_k + \rho g_k^T d_k \alpha_k = f_k - \rho \frac{g_k^2}{G_k}$$

由于 $x_k^2 \rightarrow 1$ ，所以 $\frac{g_k^2}{G_k} \rightarrow \frac{(\pm \frac{64}{91})^2}{\frac{32}{91}} = \frac{128}{91}$ 。故 $\rho \frac{g_k^2}{G_k} \rightarrow \frac{128}{91} \rho > 0$ 。

而由于 $f_k \rightarrow f(1) = f(-1)$ 且单调下降，所以 $f_k - f_{k+1} \rightarrow 0$ ，于是当 k 足够大时有 $f_k - f_{k+1} < \rho \frac{g_k^2}{G_k}$ ，即

$$f_{k+1} \leq f_k + \rho g_k^T d_k \alpha_k$$

不成立！

综上，所有命题得证。

注：基本 Newton 方法在本题中虽然产生下降的函数值序列，但步长“太大”，越过了极小点 0，导致在两边的周期点附近开始震荡。无法满足保证充分下降的 Armijo 准则（也就是最后要求验证的式子），且无法收敛到稳定点。

如果要严谨证明下降性质或收敛性，需要如上对函数进行很细致的分析和估计。

2.3 第 7 题

要证的内容为 SMW 公式。

首先一方面，当 $\sigma := 1 + v^T A^{-1} u \neq 0$ 时，有：

$$\begin{aligned} (A + uv^T)(A^{-1} - \frac{1}{\sigma} A^{-1} uv^T A^{-1}) &= I + uv^T A^{-1} - \frac{1}{\sigma} uv^T A^{-1} - \frac{1}{\sigma} uv^T A^{-1} uv^T A^{-1} \\ &= I + \frac{\sigma - 1}{\sigma} uv^T A^{-1} - \frac{u(\sigma - 1)v^T A^{-1}}{\sigma} \\ &= I \end{aligned}$$

所以此时 $A + uv^T$ 可逆，且 $(A + uv^T)^{-1} = A^{-1} - \frac{1}{\sigma} A^{-1} uv^T A^{-1}$ 。

另一方面, 当 $\sigma = 0$ 时, 取 $w = A^{-1}u$ 。

由 $v^T w = -1$, 所以 $w \neq 0$ 。进一步计算有

$$\begin{aligned}(A + uv^T)w &= (A + uv^T)A^{-1}u \\ &= u + u(v^T A^{-1}u) \\ &= \sigma u \\ &= 0\end{aligned}$$

即 $A + uv^T$ 的核空间非零, 于是不可逆!

综上, 原题得证。

2.4 第 15 题

根据式 3.31 可知, B_k 的 BFGS 公式为:

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T s_k} - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} \quad (7)$$

这里 $s_k = x_{k+1} - x_k$, $y_k = g_{k+1} - g_k$ 。

由于 B_k 的秩二更新形式可知其对称。

对公式 (7) 两边取迹, 利用算子的线性性:

$$\text{Tr}(B_{k+1}) = \text{Tr}(B_k) + \text{Tr}\left(\frac{y_k y_k^T}{y_k^T s_k}\right) - \text{Tr}\left(\frac{(B_k s_k)(B_k s_k)^T}{s_k^T B_k s_k}\right)$$

由于

$$\text{Tr}(AB) = \sum_i \left(\sum_k A_{ik} B_{ki} \right) = \sum_k \left(\sum_i B_{ki} A_{ik} \right) = \text{Tr}(BA)$$

所以上式中

$$\text{Tr}\left(\frac{y_k y_k^T}{y_k^T s_k}\right) = \frac{\text{Tr}(y_k y_k^T)}{y_k^T s_k} = \frac{\text{Tr}(y_k^T y_k)}{y_k^T s_k} = \frac{\|y_k\|^2}{y_k^T s_k}$$

同理

$$\text{Tr}\left(\frac{(B_k s_k)(B_k s_k)^T}{s_k^T B_k s_k}\right) = \frac{\text{Tr}((B_k s_k)(B_k s_k)^T)}{s_k^T B_k s_k} = \frac{\text{Tr}((B_k s_k)^T (B_k s_k))}{s_k^T B_k s_k} = \frac{\|B_k s_k\|^2}{s_k^T B_k s_k}$$

代回, 即

$$\text{Tr}(B_{k+1}) = \text{Tr}(B_k) + \frac{\|y_k\|^2}{y_k^T s_k} - \frac{\|B_k s_k\|^2}{s_k^T B_k s_k}$$

证毕。

3 作业十一

习题四: 2、7、8

3.1 第 2 题

我们来证明定理 4.2。

对于共轭向量组 $\{d_i\}$ 中的向量, 满足非零且 $i \neq j$ 时 $d_i^T G d_j = 0$ 。

假设 $\sum_{i=0}^{n-1} c_i d_i = 0$, 则有

$$\begin{aligned} 0 &= \left(\sum_{i=0}^{n-1} c_i d_i \right)^T G \left(\sum_{i=0}^{n-1} c_i d_i \right) \\ &= \sum_{i=0}^{n-1} c_i^2 d_i^T G d_i + \sum_{i \neq j} c_i c_j d_i^T G d_j \\ &= \sum_{i=0}^{n-1} c_i^2 d_i^T G d_i \end{aligned}$$

由于 G 正定, 所以对于非零向量 d_i 有 $d_i^T G d_i > 0$ 。

于是上面可以得出 $c_i^2 = 0$, 即对于每个 i 有 $c_i = 0$ 。

根据定义, 即 $\{d_i\}$ 线性无关。证毕。

3.2 第 7 题

我们使用数学归纳法进行证明。

为了简化过程, 我们定义 G -内积 $\langle u, v \rangle_G = u^T G v$ 。我们需要证明对于任意 k , 都有 $\langle d_k, d_j \rangle_G = 0$ ($j < k$)。

记系数 $\beta_{ki} = \frac{\langle p_k, d_i \rangle_G}{\langle d_i, d_i \rangle_G}$, 则递推公式可写为:

$$d_k = p_k - \sum_{i=0}^{k-1} \beta_{ki} d_i \quad (8)$$

当 $k = 1$ 时:

$$d_1 = p_1 - \beta_{10} d_0 = p_1 - \frac{\langle p_1, d_0 \rangle_G}{\langle d_0, d_0 \rangle_G} d_0$$

计算 $\langle d_1, d_0 \rangle_G$:

$$\langle d_1, d_0 \rangle_G = \langle p_1, d_0 \rangle_G - \frac{\langle p_1, d_0 \rangle_G}{\langle d_0, d_0 \rangle_G} \langle d_0, d_0 \rangle_G = \langle p_1, d_0 \rangle_G - \langle p_1, d_0 \rangle_G = 0$$

故 $k = 1$ 时结论成立。

假设对于 k 之前的向量 $d_0, d_1, \dots, d_{k-1}$, 它们两两之间满足 G -共轭性, 即:

$$\langle d_m, d_l \rangle_G = 0, \quad \forall 0 \leq l < m \leq k-1$$

现在考察 d_k 与 d_j 的 G -内积, 其中 $j \in \{0, 1, \dots, k-1\}$ 。利用公式 (8):

$$\langle d_k, d_j \rangle_G = \left\langle p_k - \sum_{i=0}^{k-1} \beta_{ki} d_i, d_j \right\rangle_G$$

由内积的线性性质展开:

$$\langle d_k, d_j \rangle_G = \langle p_k, d_j \rangle_G - \sum_{i=0}^{k-1} \beta_{ki} \langle d_i, d_j \rangle_G$$

由归纳假设, 当 $i \neq j$ 时, $\langle d_i, d_j \rangle_G = 0$ 。因此后面的求和中仅剩 $i = j$ 的一项非零:

$$\langle d_k, d_j \rangle_G = \langle p_k, d_j \rangle_G - \beta_{kj} \langle d_j, d_j \rangle_G$$

将 β_{kj} 的定义代入：

$$\langle d_k, d_j \rangle_G = \langle p_k, d_j \rangle_G - \frac{\langle p_k, d_j \rangle_G}{\langle d_j, d_j \rangle_G} \langle d_j, d_j \rangle_G$$

于是：

$$\langle d_k, d_j \rangle_G = \langle p_k, d_j \rangle_G - \langle p_k, d_j \rangle_G = 0$$

由于 j 是任意小于 k 的下标，且由于 p_k 线性无关保证了 $d_k \neq 0$ ，从而分母非零。

综上所述，由数学归纳法可知，序列 $\{d_0, \dots, d_{n-1}\}$ 是 G -共轭的。证毕。

3.3 第 8 题

目标函数可写为标准二次型形式 $f(x) = \frac{1}{2}x^T Gx + b^T x$ 。

$$f(x) = \frac{1}{2} \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 8 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} -4 & -8 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

故 Hessian 矩阵 $G = \begin{bmatrix} 2 & 0 \\ 0 & 8 \end{bmatrix}$ ，向量 $b = \begin{bmatrix} -4 \\ -8 \end{bmatrix}$ 。

梯度为 $g(x) = \nabla f(x) = Gx + b = \begin{bmatrix} 2x_1 - 4 \\ 8x_2 - 8 \end{bmatrix}$ 。

初始化：

- $x_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$
- $g_0 = Gx_0 + b = \begin{bmatrix} -4 \\ -8 \end{bmatrix}$
- FR 方法初始方向 $d_0 = -g_0 = \begin{bmatrix} 4 \\ 8 \end{bmatrix}$

迭代：由第一次作业第 5 题结论，计算精确线搜索步长 $\alpha_0 = -\frac{d_0^T g_0}{d_0^T G d_0} = \frac{16+64}{16*2+64*8} = \frac{5}{34}$ 。
更新 x ：

$$x_1 = x_0 + \alpha_0 d_0 = \frac{5}{34} \begin{bmatrix} 4 \\ 8 \end{bmatrix} = \begin{bmatrix} 20/34 \\ 40/34 \end{bmatrix} = \begin{bmatrix} 10/17 \\ 20/17 \end{bmatrix}$$

计算新梯度 g_1 ：

$$g_1 = \begin{bmatrix} 2(10/17) - 4 \\ 8(20/17) - 8 \end{bmatrix} = \begin{bmatrix} 20/17 - 68/17 \\ 160/17 - 136/17 \end{bmatrix} = \begin{bmatrix} -48/17 \\ 24/17 \end{bmatrix}$$

即 $g_1 = \frac{24}{17} \begin{bmatrix} -2 \\ 1 \end{bmatrix}$ 。

求更新方向：计算 β_0 (FR 公式)：

$$\beta_0 = \frac{\|g_1\|^2}{\|g_0\|^2} = \frac{\frac{2880}{289}}{80} = \frac{36}{289}$$

计算新的迭代方向 d_1 ：

$$d_1 = -g_1 + \beta_0 d_0 = -\begin{bmatrix} -48/17 \\ 24/17 \end{bmatrix} + \frac{36}{289} \begin{bmatrix} 4 \\ 8 \end{bmatrix} = \frac{120}{289} \begin{bmatrix} 8 \\ -1 \end{bmatrix}$$

迭代：由第一次作业第 5 题结论，计算精确线搜索步长 $\alpha_1 = -\frac{d_1^T g_1}{d_1^T G d_1} = -\frac{17}{5} \frac{-2*8-1*1}{64*2+1*8} = \frac{17}{40}$ 。

更新 x ：

$$x_2 = x_1 + \alpha_1 d_1 = \begin{bmatrix} 10/17 \\ 20/17 \end{bmatrix} + \frac{17}{40} \frac{120}{289} \begin{bmatrix} 8 \\ -1 \end{bmatrix} = \begin{bmatrix} 34/17 \\ 17/17 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

此即为精确解 $x^* = [2, 1]^T$ 。

下面验证三个性质：

验证 (4.10a) 方向关于 G 共轭： $d_1^T G d_0 = 0$

$$G d_0 = \begin{bmatrix} 2 & 0 \\ 0 & 8 \end{bmatrix} \begin{bmatrix} 4 \\ 8 \end{bmatrix} = \begin{bmatrix} 8 \\ 64 \end{bmatrix}$$

$$d_1^T G d_0 = \left(\frac{120}{289} \begin{bmatrix} 8 \\ -1 \end{bmatrix} \right)^T \begin{bmatrix} 8 \\ 64 \end{bmatrix} = \frac{120}{289} (8 \times 8 + (-1) \times 64) = \frac{120}{289} (64 - 64) = 0$$

结论：成立。

验证 (4.10b) 梯度相互正交： $g_1^T g_0 = 0$

$$g_1^T g_0 = \left(\frac{24}{17} \begin{bmatrix} -2 \\ 1 \end{bmatrix} \right)^T \begin{bmatrix} -4 \\ -8 \end{bmatrix} = \frac{24}{17} ((-2)(-4) + (1)(-8)) = \frac{24}{17} (8 - 8) = 0$$

结论：成立。

验证 (4.10c) 梯度与下降方向关系需要验证两部分：

1. $d_0^T g_0 = -\|g_0\|^2$ ：

这一点由 $d_0 = -g_0$ 是显然的。

2. $d_1^T g_1 = -\|g_1\|^2$ ：

左边：

$$d_1^T g_1 = \left(\frac{120}{289} \begin{bmatrix} 8 \\ -1 \end{bmatrix} \right)^T \left(\begin{bmatrix} -48/17 \\ 24/17 \end{bmatrix} \right) = \frac{24}{17} \frac{120}{289} \begin{bmatrix} 8 \\ -1 \end{bmatrix}^T \begin{bmatrix} -2 \\ 1 \end{bmatrix} = -\frac{2880}{289}$$

右边：

$$-\|g_1\|^2 = -\frac{2880}{289} \quad (\text{见上面中间步骤的计算结果})$$

左右两边相等。**结论：**成立。

于是三个结论都成立。

注：对于二次正定目标函数，若使用精确线搜索，FR 共轭梯度法和使用单位矩阵近似初始矩阵的 BFGS 法产生的迭代点序列 $\{x_k\}$ 和搜索方向 $\{d_k\}$ (归一化后) 理论上是一致的。这一点可以通过验证 BFGS 产生的方向的共轭性用归纳法可以证。

4 作业十二

习题六：5、10、11

4.1 第 5 题

假设在 x^* 处存在两组 Lagrange 乘子 $\lambda = (\lambda_1, \dots, \lambda_m)^T$ 和 $\mu = (\mu_1, \dots, \mu_m)^T$ 均满足 KKT 条件。

根据 KKT 条件中 (6.14a) 式, 我们有:

$$g(x^*) = \sum_{i=1}^m \lambda_i a_i(x^*)$$

$$g(x^*) = \sum_{i=1}^m \mu_i a_i(x^*)$$

这里 $\mathcal{A}^*$ 是在 x^* 处起作用约束集合 (即 $c_i(x^*) = 0$ 的约束下标集合)。对于非有效约束 $i \notin \mathcal{A}^*$, 由互补松弛条件 (6.14e) 式可知 $\lambda_i = 0$ 且 $\mu_i = 0$ 。因此我们只需讨论有效约束对应的乘子。

将上面两式相减有:

$$\sum_{i \in \mathcal{A}^*} (\mu_i - \lambda_i) a_i(x^*) = 0$$

题目已知 $\{a_i(x^*) \mid i \in \mathcal{A}^*\}$ 线性无关, 根据线性无关的定义, 若线性组合为零向量, 则组合系数必须全为零。

因此:

$$\mu_i - \lambda_i = 0, \quad \forall i \in \mathcal{A}^*$$

即 $\lambda_i = \mu_i$ 。

结合非有效约束下标对应应有 $\lambda_i = \mu_i = 0$, 可知 $\lambda = \mu$ 。因此乘子是唯一的。证毕。

4.2 第 10 题

问题 (1)

题目为:

$$\begin{aligned} \min \quad & f(x) := (x_1 - 1)^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & c_1(x) := (x_1 - 1)^2 - 5x_2 = 0 \end{aligned}$$

引入 Lagrange 乘子 λ , 构造 Lagrange 函数:

$$L(x, \lambda) = (x_1 - 1)^2 + (x_2 - 2)^2 - \lambda[(x_1 - 1)^2 - 5x_2]$$

于是 KKT 条件方程组为:

$$\frac{\partial L}{\partial x_1} = 2(x_1 - 1) - 2\lambda(x_1 - 1) = 2(x_1 - 1)(1 - \lambda) = 0 \quad (9)$$

$$\frac{\partial L}{\partial x_2} = 2(x_2 - 2) + 5\lambda = 0 \quad (10)$$

$$c_1(x) = (x_1 - 1)^2 - 5x_2 = 0 \quad (11)$$

由 (9) 可知, 要么 $x_1 = 1$, 要么 $\lambda = 1$ 。

- **情形 1:** 设 $x_1 = 1$ 。代入 (11): $(1 - 1)^2 - 5x_2 = 0 \implies x_2 = 0$ 。代入 (10) 求 λ : $2(0 - 2) + 5\lambda = 0 \implies 5\lambda = 4 \implies \lambda = 0.8$ 。得到 KKT 点 $x^{(1)} = (1, 0)^T$, $\lambda = 0.8$ 。

- **情形 2:** 设 $\lambda = 1$ 。代入 (10): $2(x_2 - 2) + 5 = 0 \implies 2x_2 = -1 \implies x_2 = -0.5$ 。代入 (11): $(x_1 - 1)^2 = 5(-0.5) = -2.5$ 。实数范围内无解。

唯一的 KKT 点是 $x^* = (1, 0)^T$ 。验证二阶条件: $\nabla_{xx}^2 L = \begin{bmatrix} 2 - 2\lambda & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 2(1 - 0.8) & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 0.4 & 0 \\ 0 & 2 \end{bmatrix}$ 。该矩阵是正定的, 满足极小值点的二阶充分条件。

结论: KKT 点 $x^* = (1, 0)^T$ 是最优解。又由于在这个乘子下二阶导恒正定, 于是全局存在唯一极小值, 所以 KKT 点是全局最优解。

2. 问题 (2)

题目为:

$$\begin{aligned} \min \quad & f(x) := (x_1 + x_2)^2 + 2x_1 + x_2^2 = x_1^2 + 2x_1x_2 + 2x_2^2 + 2x_1 \\ \text{s.t.} \quad & c_1(x) := 4 - x_1 - 3x_2 \geq 0 \\ & c_2(x) := 3 - 2x_1 - x_2 \geq 0 \\ & c_3(x) := x_1 \geq 0 \\ & c_4(x) := x_2 \geq 0 \end{aligned}$$

引入 Lagrange 乘子 $\lambda_i \geq 0, i = 1, 2, 3, 4$, 对应的 Lagrange 函数定义为 $L = f - \sum_{i=1}^4 \lambda_i c_i$ 。

首先求导可知: $\nabla f = \begin{bmatrix} 2x_1 + 2x_2 + 2 \\ 2x_1 + 4x_2 \end{bmatrix}$ 。

KKT 条件的方程组为:

$$\frac{\partial L}{\partial x_1} = 2x_1 + 2x_2 + 2 + \lambda_1 + 2\lambda_2 - \lambda_3 = 0 \quad (12)$$

$$\frac{\partial L}{\partial x_2} = 2x_1 + 4x_2 + 3\lambda_1 + \lambda_2 - \lambda_4 = 0 \quad (13)$$

$$c_i(x) \geq 0 \quad (14)$$

$$\lambda_i c_i(x) = 0 \quad (15)$$

由于 x_i 与 λ_i 均非负, 所以代入(12)可知 $\lambda_3 > 0$ 。由互补条件(15)可知 $c_3(x) = 0$, 即 $x_1 = 0$ 。

此时若 $\lambda_4 > 0$, 则依然由互补条件知 $c_4(x) = 0$, 即 $x_2 = 0$ 。由(13)可知 $3\lambda_1 + \lambda_2 = \lambda_4 > 0$, 于是由互补松弛条件 $c_1(x)$ 和 $c_2(x)$ 至少一个为 0, 但是这与 $x_1 = x_2 = 0$ 矛盾!

所以我们可得 $\lambda_4 = 0$, 于是代入(13)可知 $x_1 = x_2 = \lambda_1 = \lambda_2 = 0$ 。代回(12)于是 $\lambda_3 = 2$ 。

我们解得 $x_1 = x_2 = 0, \lambda_1 = \lambda_2 = \lambda_4 = 0, \lambda_3 = 2$, 代回满足上面提到的所有方程, 为唯一的 KKT 对。

对于唯一的 KKT 点 $x^* = (0, 0)^T$, 检查二阶条件: $\nabla_{xx}^2 L = \begin{bmatrix} 2 & 2 \\ 2 & 4 \end{bmatrix}$, 为正定矩阵, 满足极小值点的二阶充分条件。

结论: KKT 点 $x^* = (0, 0)^T$ 是最优解。又由于在这个乘子下二阶导恒正定, 于是全局存在唯一极小值, 所以 KKT 点是全局最优解。

4.3 第 11 题

目标函数 $f(x) = x_1^2 + 4x_2^2 + 16x_3^2$ 。梯度 $\nabla f = (2x_1, 8x_2, 32x_3)^T$ 。Lagrange 函数 $L(x, \lambda) = f(x) - \lambda c(x)$ 。KKT 方程: $\nabla f(x) = \lambda \nabla c(x)$ 以及 $c(x) = 0$ 。

1. 约束 $c(x) = x_1 - 1 = 0$

$\nabla c = (1, 0, 0)^T$ 。于是方程组化为:

$$\begin{cases} 2x_1 = \lambda \cdot 1 \\ 8x_2 = \lambda \cdot 0 \implies x_2 = 0 \\ 32x_3 = \lambda \cdot 0 \implies x_3 = 0 \\ x_1 = 1 \end{cases}$$

解得 $x^* = (1, 0, 0)^T$, $\lambda = 2$ 。

检查二阶条件: $\nabla_{xx}^2 L = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 8 & 0 \\ 0 & 0 & 16 \end{bmatrix}$, 为正定矩阵, 满足极小值点的二阶充分条件。

又由于在这个乘子下二阶导恒正定, 于是为凸函数, 全局存在唯一极小值, 所以 KKT 点 $x^* = (1, 0, 0)^T$ 是**全局最优解**。

2. 约束 $c(x) = x_1x_2 - 1 = 0$

$\nabla c = (x_2, x_1, 0)^T$ 。于是方程组化为:

$$\begin{cases} 2x_1 = \lambda x_2 & (1) \\ 8x_2 = \lambda x_1 & (2) \\ 32x_3 = 0 \implies x_3 = 0 \\ x_1x_2 = 1 & (3) \end{cases}$$

由 (3) 知 x_1, x_2 非零。由 (1) 得 $\lambda = \frac{2x_1}{x_2}$, 代入 (2):

$$8x_2 = \left(\frac{2x_1}{x_2}\right)x_1 \implies 4x_2^2 = x_1^2 \implies x_1 = \pm 2x_2$$

代入约束 $x_1x_2 = 1$: 若 $x_1 = 2x_2$, 则 $2x_2^2 = 1 \implies x_2 = \pm \frac{1}{\sqrt{2}}$ 。若 $x_1 = -2x_2$, 则 $-2x_2^2 = 1$, 无实数解。

因此有两个 KKT 点: $P_1: x = (\sqrt{2}, \frac{1}{\sqrt{2}}, 0)^T$, 此时 $\lambda = \frac{2\sqrt{2}}{1/\sqrt{2}} = 4$ 。 $P_2: x = (-\sqrt{2}, -\frac{1}{\sqrt{2}}, 0)^T$, 此时 $\lambda = 4$ 。

代入可知 $f(P_1) = 2 + 4(1/2) + 0 = 4$ 且 $f(P_2) = 4$ 。而由均值不等式可知, 在这个约束下: $f(x) \geq x_1^2 + 4x_2^2 \geq 2\sqrt{x_1^2 \cdot 4x_2^2} = 4|x_1x_2| = 4$ 。故这两个 KKT 点均为 **全局最优解**。

3. 约束 $c(x) = x_1x_2x_3 - 1 = 0$

$\nabla c = (x_2x_3, x_1x_3, x_1x_2)^T$ 。于是方程组化为:

$$\begin{cases} 2x_1 = \lambda x_2x_3 & \xrightarrow{\times x_1} & 2x_1^2 = \lambda x_1x_2x_3 = \lambda \\ 8x_2 = \lambda x_1x_3 & \xrightarrow{\times x_2} & 8x_2^2 = \lambda x_1x_2x_3 = \lambda \\ 32x_3 = \lambda x_1x_2 & \xrightarrow{\times x_3} & 32x_3^2 = \lambda x_1x_2x_3 = \lambda \end{cases}$$

由约束 $x_1x_2x_3 = 1$, 可知 $x_i \neq 0$ 。由此得到比例关系:

$$2x_1^2 = 8x_2^2 = 32x_3^2 = \lambda$$

且需满足 $x_1x_2x_3 = 1$ 。

由平方关系: $x_1^2 = 4x_2^2 \implies |x_1| = 2|x_2|$ 。 $x_1^2 = 16x_3^2 \implies |x_1| = 4|x_3|$ 。即 $|x_2| = \frac{1}{2}|x_1|, |x_3| = \frac{1}{4}|x_1|$ 。

代入约束绝对值: $|x_1| \cdot \frac{|x_1|}{2} \cdot \frac{|x_1|}{4} = 1 \implies \frac{|x_1|^3}{8} = 1 \implies |x_1| = 2$ 。进而 $|x_2| = 1, |x_3| = 0.5$ 。

再考虑符号, 需满足 $x_1x_2x_3 = 1 > 0$ 。即三者同号, 或两负一正。于是有下面的几种情况:

- 三正: $(2, 1, 0.5)$
- 两负一正 (3 种): $(2, -1, -0.5)$ $(-2, 1, -0.5)$ $(-2, -1, 0.5)$

共有 4 个 KKT 点。此时 $\lambda = 2(2)^2 = 8$ 。

这些点处的函数值均为 $f^* = 2^2 + 4(1)^2 + 16(0.5)^2 = 12$ 。而由均值不等式可知: $f(x) = x_1^2 + 4x_2^2 + 16x_3^2 \geq 3\sqrt[3]{x_1^2 \cdot 4x_2^2 \cdot 16x_3^2} = 3\sqrt[3]{64(x_1x_2x_3)^2} = 3\sqrt[3]{64 \cdot 1} = 3 \times 4 = 12$ 。因此, 这 4 个 KKT 点均为 **全局最优解**。